

Modelado predictivo de variables climáticas y sus acercamientos a calendarios agrícolas en el Valle de México

Valentina Carrillo Benítez

Reconocimiento de patrones y aprendizaje automatizado

Abstract

El cambio climático ha alterado significativamente los patrones estacionales tradicionales en el Valle de México, afectando directamente las actividades agrícolas y el conocimiento ancestral de las comunidades indígenas. Este trabajo presenta un enfoque de aprendizaje supervisado para predecir eventos climáticos de riesgo (heladas, sequías e inundaciones) y optimizar fechas de siembra y cosecha. Se implementaron y compararon modelos de Kernel Ridge Regression (KRR) y Support Vector Regression (SVR) con kernels lineal y RBF. Los resultados muestran que SVR con kernel RBF alcanza el mejor desempeño ($MAE = 0.1558$, $RMSE = 0.2318$), demostrando la naturaleza no lineal de las relaciones climáticas. El modelo propuesto permite recomendar fechas óptimas para actividades agrícolas con bajo riesgo climático.

1 Introducción

Dentro del conocimiento vivo de nuestras comunidades indígenas y agricultoras, la clave para la sostenibilidad en comunidad se basa en la puntualidad del cultivo de las especies que forman parte de la alimentación y el comercio tanto local como externo, ya sea la cosecha de elotes la tercera semana de septiembre, o la siembra del cempasúchitl el día de San Juan Bautista.

Este conocimiento, sin embargo, se ha visto opacado en los últimos años debido al cambio climático, dando pie a la modificación de fechas de cultivo que terminan eligiéndose de forma casi aleatoria, con el fin de encontrar las condiciones climáticas óptimas para el desarrollo de los productos.

Derivado del cambio climático, las fechas de siembra, cultivo y cosecha de plantas en las comunidades indígenas o agricultoras se han visto alteradas gravemente. Para este proyecto se buscará, por medio del aprendizaje supervisado, encontrar fechas convenientes para las actividades agrícolas en el Valle de México.

2 Objetivo

Crear predicciones sobre eventos climáticos en el año actual o el siguiente con el fin de optimizar las fechas de cultivo de plantas, mediante:

- Identificación de patrones climáticos asociados a heladas, sequías e inundaciones
- Implementación de modelos de regresión con kernel (lineal y no lineal)
- Comparación cuantitativa de modelos mediante métricas de error
- Recomendación de fechas óptimas para siembra y cosecha

3 Marco teórico

3.1 Support Vector Regression (SVR)

SVR es una extensión de Support Vector Machines (SVM) para problemas de regresión [1]. A diferencia de la regresión tradicional que minimiza el error cuadrático, SVR introduce una región de insensibilidad (ϵ -tube) donde no se penalizan los errores.

3.1.1 Formulaci3n Lineal

La funci3n de regresi3n lineal se define como:

$$f(x) = \langle w, x \rangle + b = \sum_{i=1}^d w_i x_i + b \quad (1)$$

donde:

- w : vector de pesos
- x : vector de caracteristicas
- b : sesgo
- $\langle w, x \rangle$: producto punto

La funci3n de p3rdida ϵ -insensitive est1 dada por:

$$L(y, f(x)) = \max(0, |y - f(x)| - \epsilon) \quad (2)$$

El problema de optimizaci3n se formula como [2]:

$$\min_{w, b} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n (\xi_i + \xi_i^*) \quad (3)$$

sujeto a:

$$y_i - \langle w, x_i \rangle - b \leq \epsilon + \xi_i \quad (4)$$

$$\langle w, x_i \rangle + b - y_i \leq \epsilon + \xi_i^* \quad (5)$$

$$\xi_i, \xi_i^* \geq 0 \quad (6)$$

donde C es el par1metro de regularizaci3n y ξ_i, ξ_i^* son variables de holgura.

3.1.2 Formulaci3n con Kernel No Lineal

Para capturar relaciones no lineales, SVR utiliza el kernel trick [3]:

$$f(x) = \sum_{i=1}^n \alpha_i K(x_i, x) + b \quad (7)$$

donde α_i son los coeficientes duales y K es la funci3n kernel.

3.1.3 Kernel RBF (Radial Basis Function)

El kernel RBF se define como:

$$K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2) \quad (8)$$

donde $\gamma > 0$ controla el ancho de la funci3n gaussiana:

- γ peque1a: funci3n suave, influencia de largo alcance
- γ grande: funci3n ajustada, influencia local

3.2 Regresi3n Ridge Lineal

La regresi3n Ridge constituye una extensi3n de la regresi3n lineal cl1sica que incorpora un t3rmino de regularizaci3n para reducir el sobreajuste y mejorar la capacidad de generalizaci3n del modelo. En problemas clim1ticos, las variables predictoras suelen presentar correlaciones elevadas entre s1; por ejemplo, la precipitaci3n, la evaporaci3n y la temperatura est1n relacionadas por procesos f1sicos comunes. Esta situaci3n puede generar estimaciones inestables de los coeficientes en una regresi3n lineal ordinaria.

La funci3n de predicci3n de Ridge se expresa como:

$$\hat{y} = Xw + b$$

donde (X) representa la matriz de características climáticas, (w) es el vector de pesos asociados a cada variable y (b) corresponde al término de sesgo.

El modelo se ajusta minimizando la siguiente función objetivo:

$$J(w) = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_j w_j^2$$

El primer término mide el error cuadrático entre los valores observados y los predichos, mientras que el segundo penaliza coeficientes excesivamente grandes mediante el parámetro de regularización λ . Cuando λ aumenta, el modelo reduce la magnitud de los coeficientes y se vuelve menos sensible al ruido presente en los datos.

La solución analítica está dada por:

$$w = (X^T X + \lambda I)^{-1} X^T y$$

donde (I) es la matriz identidad. Esta formulación permite obtener estimaciones más estables que las de la regresión lineal ordinaria cuando existe multicolinealidad entre las variables predictoras.

3.3 Kernel Ridge Regression (KRR)

KRR combina la regresión Ridge con el kernel trick [4]:

$$\min_{f \in \mathcal{H}} \sum_{i=1}^n (y_i - f(x_i))^2 + \lambda \|f\|_{\mathcal{H}}^2 \quad (9)$$

La solución tiene la forma:

$$f(x) = \sum_{i=1}^n \alpha_i K(x_i, x) \quad (10)$$

con $\alpha = (K + \lambda I)^{-1} y$, donde K es la matriz de kernel.

4 Metodología

4.1 Obtención de Datos

Los datos fueron obtenidos directamente de la página oficial del Sistema Meteorológico Nacional (SMN-CONAGUA). Se recolectaron registros diarios de precipitación (PRECIP), evaporación (EVAP), temperatura máxima (TMAX) y temperatura mínima (TMIN) para el Valle de México.

- Período: 5 años (2020-2025)
- Frecuencia: 15 registros por mes
- Total de registros: 900
- Variables: PRECIP, EVAP, TMAX, TMIN, FECHA

4.2 Preprocesamiento

4.2.1 Limpieza de Datos

```
df["FECHA"] = pd.to_datetime(df["FECHA"])
df["TMIN"] = pd.to_numeric(df["TMIN"], errors='coerce')
df["EVAP"] = pd.to_numeric(df["EVAP"], errors='coerce')
df["PRECIP"] = pd.to_numeric(df["PRECIP"], errors='coerce')
df.dropna(inplace=True)
```

4.2.2 Normalización

Las características fueron normalizadas usando StandardScaler:

$$X_{\text{scaled}} = \frac{X - \mu}{\sigma} \quad (11)$$

4.3 Definición de Eventos de Riesgo

4.3.1 Helada

$$H_i = \begin{cases} 1 & \text{si } TMin \leq 0^\circ C \\ 0 & \text{en caso contrario} \end{cases} \quad (12)$$

4.3.2 Inundación

$$I_i = \begin{cases} 1 & \text{si } PRECIP > 100 \text{ mm} \\ 0 & \text{en caso contrario} \end{cases} \quad (13)$$

4.3.3 Sequía

Para cada mes m , se calcula el percentil 30 de la precipitación histórica:

$$P_{30}^{(m)} = \text{percentil}_{30} (\{PRECIP_i : MES_i = m\}) \quad (14)$$

La clasificación de sequía es:

$$S_i = \begin{cases} 1 & \text{si } PRECIP < P_{30}^{(MES)} \\ 0 & \text{en caso contrario} \end{cases} \quad (15)$$

4.3.4 Riesgo Total

$$RIESGO = H_i \vee S_i \vee I_i \quad (16)$$

4.4 Características

4.4.1 Variables Cíclicas Temporales

Para capturar estacionalidad:

Las variables temporales presentan una naturaleza periódica. Por ejemplo, el día 365 y el día 1 del año son temporalmente cercanos, aunque sus valores numéricos sean muy distintos. Para preservar esta estructura circular, se empleó una codificación trigonométrica basada en funciones seno y coseno [6]:

$$\text{dia_sin} = \sin\left(2\pi \frac{\text{día_año}}{365}\right) \quad (17)$$

$$\text{dia_cos} = \cos\left(2\pi \frac{\text{día_año}}{365}\right) \quad (18)$$

Esta transformación proyecta cada día del año sobre una circunferencia unitaria, permitiendo que fechas cercanas al inicio y final del año mantengan una representación similar en el espacio de características.

4.4.2 Variables con Rezago (Lags)

Para modelar dependencias temporales:

$$x_i = [PRECIP_i, EVAP_i, TMAX_i, TMIN_i, \text{dia_sin}_i, \text{dia_cos}_i, \quad (19)$$

$$PRECIP_{i-1}, EVAP_{i-1}, TMAX_{i-1}, TMIN_{i-1}, \quad (20)$$

$$PRECIP_{i-2}, EVAP_{i-2}, TMAX_{i-2}, TMIN_{i-2}] \quad (21)$$

4.5 División Entrenamiento-Prueba

```
fecha_corte = "2023-01-01"
train = df[df["FECHA"] < fecha_corte] # 2020-2023
test = df[df["FECHA"] >= fecha_corte] # 2024-2025
```

5 Experimentación

5.1 Configuración de Modelos

5.1.1 Kernel Ridge Regression (KRR)

```
# Lineal
modelo_lineal = KernelRidge(alpha=1.0, kernel="linear")

# RBF
modelo_rbf = KernelRidge(alpha=1.0, kernel="rbf", gamma=0.1)
```

5.1.2 Support Vector Regression (SVR)

```
# Lineal
svr_lineal = SVR(kernel="linear", C=1.0, epsilon=0.1)

# RBF
svr_rbf = SVR(kernel="rbf", C=1.0, gamma=0.1, epsilon=0.1)
```

5.2 Métricas de Evaluación

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (22)$$

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (23)$$

6 Resultados

6.1 Resultados de Clasificación (SVM)

La Tabla 1 muestra la precisión obtenida por SVM con diferentes kernels.

Table 1: Precisión de clasificación

Kernel	Precisión
Lineal	0.8528
RBF	0.9239

6.2 Matrices de Confusión

Table 2: Matriz de confusión - Kernel Lineal

		Predicho	
		0	1
Real	0	153	0
	1	29	15

Table 3: Matriz de confusión - Kernel RBF

		Predicho	
		0	1
Real	0	151	2
	1	13	31

6.3 Resultados de Regresión (KRR vs SVR)

La Tabla 4 presenta la comparación de modelos.

Table 4: Comparación de modelos - MAE y RMSE

Modelo	MAE	RMSE
KRR Lineal	0.2644	0.3496
KRR RBF	0.1593	0.2616
SVR Lineal	0.2058	0.2868
SVR RBF	0.1558	0.2318

6.4 Análisis de Resultados

6.4.1 Comparación entre KRR y SVR

Los resultados obtenidos muestran diferencias importantes entre los modelos evaluados. En primer lugar, tanto para KRR como para SVR, el uso del kernel RBF produjo una reducción significativa del error respecto a sus versiones lineales. Este comportamiento indica que la relación entre las variables meteorológicas y el nivel de riesgo climático no puede describirse adecuadamente mediante una combinación lineal de características.

En el caso de KRR, el cambio de kernel lineal a RBF redujo el MAE de 0.2644 a 0.1593, mientras que el RMSE disminuyó de 0.3496 a 0.2616. De manera similar, SVR redujo el MAE de 0.2058 a 0.1558 y el RMSE de 0.2868 a 0.2318 al utilizar el kernel RBF.

El mejor desempeño global fue alcanzado por SVR con kernel RBF. Este modelo obtuvo el menor error absoluto promedio y la menor penalización de errores grandes, lo que sugiere una mejor capacidad para capturar patrones complejos en los datos climáticos históricos.

La superioridad de SVR puede explicarse por el uso de la función de pérdida ϵ -insensitive, la cual ignora pequeñas desviaciones alrededor de la predicción y concentra el proceso de optimización en errores relevantes. Esta característica reduce la influencia de observaciones atípicas y favorece una mayor robustez frente a la variabilidad natural presente en los registros meteorológicos.

- SVR Lineal mejora KRR Lineal en 22.2% MAE
- SVR RBF mejora KRR RBF en 2.2% MAE

6.4.2 Interpretación de Errores

Dado que $\text{RIESGO} \in [0, 1]$:

- MAE = 0.1558: error absoluto promedio de $\pm 15.6\%$
- RMSE = 0.2318: penalización de errores grandes
- Error relativo: 15-23% de la escala completa

6.5 Predicción de Fechas Óptimas

6.5.1 Selección de Fecha Cercana

```
def fecha_optima(fecha_objetivo, ventana_dias=20):  
    # Encuentra fecha con menor riesgo en ventana de  $\pm 20$  días  
    ...
```

6.5.2 Ejemplos de Predicciones

Table 5: Predicciones de RIESGO_SCORE

Fecha	RIESGO_SCORE	Interpretación
2024-06-08	-0.0559	Riesgo muy bajo
2025-04-04	-0.0597	Riesgo muy bajo

7 Discusión

7.1 Ventajas del Kernel RBF

El desempeño superior del kernel RBF puede atribuirse a su capacidad para modelar relaciones no lineales entre las variables climáticas. Los procesos atmosféricos rara vez evolucionan de manera lineal; por ejemplo, pequeños cambios en la temperatura mínima pueden incrementar abruptamente la probabilidad de heladas, mientras que aumentos graduales de precipitación pueden producir efectos muy distintos dependiendo de la humedad acumulada previamente.

A diferencia de los modelos lineales, el kernel RBF transforma implícitamente los datos a un espacio de mayor dimensión donde estas relaciones complejas pueden representarse de forma más efectiva. Esto permite detectar umbrales críticos, modelar interacciones entre variables sin necesidad de diseñarlas manualmente y capturar patrones estacionales asociados al ciclo anual. Los resultados experimentales confirman esta ventaja, ya que el kernel RBF redujo consistentemente los errores de predicción en comparación con las versiones lineales de ambos modelos.

Finalmente, aunque la clasificación binaria permite identificar la presencia o ausencia de riesgo, resulta más útil predecir un índice continuo de riesgo climático. Esto permite ordenar fechas según su nivel de seguridad y seleccionar aquellas con menor probabilidad de eventos adversos.

7.2 Interpretación Agrícola

Las fechas identificadas con menor riesgo corresponden principalmente a periodos de transición entre la temporada seca y la temporada de lluvias.

Para cultivos como maíz y cempasúchil, estas fechas permiten a los agricultores reducir pérdidas por heladas tempranas, disminuir el estrés hídrico en las especies y evitar daños por precipitaciones extremas, entre otros.

8 Conclusiones

El SVR con kernel RBF es el modelo óptimo para predecir el riesgo climático en el Valle de México, logrando un error absoluto promedio de 0.156 en una escala de 0 a 1. La superioridad del kernel RBF confirma la presencia de relaciones no lineales entre las variables climáticas y el riesgo de inundaciones, sequías y heladas.

El modelo desarrollado permite recomendar fechas óptimas para actividades agrícolas con bajo riesgo climático, contribuyendo a la preservación del conocimiento tradicional y la adaptación al cambio climático en comunidades indígenas y agricultoras del Valle de México.

Los resultados obtenidos sugieren que las técnicas modernas de aprendizaje automático pueden complementar el conocimiento agrícola tradicional mediante la identificación objetiva de patrones climáticos. La integración de modelos predictivos con calendarios agrícolas podría contribuir a reducir pérdidas económicas y mejorar la capacidad de adaptación de las comunidades rurales frente al cambio climático.

References

- [1] Smola, A. J., & Schölkopf, B. (2004). A tutorial on support vector regression. *Statistics and Computing*, 14(3), 199-222.
- [2] Drucker, H., Burges, C. J., Kaufman, L., Smola, A., & Vapnik, V. (1997). Support vector regression machines. *Advances in Neural Information Processing Systems*, 9, 155-161.
- [3] Schölkopf, B., & Smola, A. J. (2002). *Learning with kernels: support vector machines, regularization, optimization, and beyond*. MIT press.
- [4] Saunders, C., Gammerman, A., & Vovk, V. (1998). Ridge regression learning algorithm in dual variables. *Proceedings of the 15th International Conference on Machine Learning*, 515-521.
- [5] Fernández, J. C., & García, F. J. (2018). Support Vector Regression for time series forecasting: A review. *Neurocomputing*, 280, 36-47.
- [6] Zheng, Alice and Casari. (2018) Feature Engineering for Machine Learning: Principles and Techniques for Data Scientists. *O'Reilly Media*

A Código de Implementación

A.1 Normalización

```
from sklearn.preprocessing import StandardScaler
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)
```

A.2 Función de Evaluación

```
def evaluar_modelo(nombre, y_real, y_pred):
    mae = mean_absolute_error(y_real, y_pred)
    rmse = np.sqrt(mean_squared_error(y_real, y_pred))
    print(f"{nombre}: MAE={mae:.4f}, RMSE={rmse:.4f}")
```

A.3 Selección de Fechas

Dado:

$$RIESGO_SCORE = \frac{H_i + S_i + I_i}{3} \quad (24)$$

```
def mejor_fecha_intervalo(fecha_inicio, fecha_fin):
    candidatos = df[(df["FECHA"] >= inicio) & (df["FECHA"] <= fin)]
    return candidatos.loc[candidatos["RIESGO_SCORE"].idxmin()]
```